

Datawarehouse y Data lake

A dark blue diagonal gradient bar that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

Índice

1. [Datawarehouse](#)
2. [Data lake](#)

1

Datawarehouse

¿Qué es un Data Warehouse?

Es un **repositorio de datos** que:

- Posee muy fácil acceso.
- Consolida muchas fuentes de datos, en un único almacén de datos.
- Transforma los datos en grupos de información sobre temas específicos de negocios, por ejemplo ventas, logística, producción, etc.
- Permite realizar fácilmente consultas, análisis, reportes para la toma de decisiones.

Objetivos del Datawarehouse

- ✓ **Tener información accesible:** los contenidos del Datawarehouse son entendibles, navegables y de rápido acceso ¡Es muy fácil hacer consultas!
- ✓ **Tener información consistente:** es decir, con un único significado para todos.
- ✓ **Tener información adaptable y elástica:** el Datawarehouse está diseñado para cambios continuos.
- ✓ **Proteger la información** y el gobierno de datos.
- ✓ **Obtener información** para la toma de decisiones.

Objetivos del Datawarehouse

Una característica esencial de cualquier datawarehouse es que nos tiene que **brindar una visión unificada y completa de los datos** a lo que comúnmente nos referiremos como una visión 360°: es decir **podemos ver en forma completa y desde cualquier ángulo** los datos de la empresa.


CARACTERÍSTICAS DEL DATAWAREHOUSE

El Datawarehouse tiene como característica **ofrecer los datos unificados en único lugar** que representen a las mismas entidades (por ej. los clientes o los productos) de una manera unificada, **sin importar el origen de esos datos.**

CARACTERÍSTICAS DEL DATAWAREHOUSE

Transaccional	Data Warehouse
Sistema	Datawarehouse
Los modelos de datos están orientados a ser eficientes y seguros en la gestión de las transacciones (ventas, compras, gestiones, reclamos, altas de clientes, etc.).	El modelo de datos de un Datawarehouse está orientado y focalizado en ayudarnos a integrar los datos, unificarlos y acceder de manera ágil y desde herramientas de visualización.
Prioriza la “escritura” de datos. Garantiza el registro de los datos.	Prioriza la “Lectura” de los datos. Agiliza la consulta de los datos.

Implementación del Datawarehouse



Arquitectura del Datawarehouse

La arquitectura de un Datawarehouse comprende 4 componentes principales:

1. [Aplicaciones fuentes de datos.](#)
2. [Procesos ETL.](#)
3. [La base de datos del Datawarehouse.](#)
4. [Herramientas de visualización y minería de datos.](#)

Arquitectura del Datawarehouse - Fuentes de datos

Las Fuentes de Datos que alimentan el Datawarehouse son típicamente los sistemas transaccionales con los cuáles las empresas realizan la registración de sus transacciones.


Arquitectura del Datawarehouse - Fuentes de datos

Pueden ser:

- **Aplicaciones formales:** ERP, CRM, E-commerce, sistemas desarrollados internamente, sistemas de RRHH, etc.
- **Aplicaciones externas a la empresa**, como por ejemplo redes sociales, Google Analytics, informes de mercado, información de entes de control de una determinada industria (como por ejemplo los entes de control, bancos, compañías de seguros, alimentos, farmacéuticas, impuestos, salud y accidentes de trabajo, etc.).
- **Información que no está formalizada** u organizada en sistemas sino que se almacena en planillas de cálculo archivos CSV, TXT o incluso PDF, entre otros formatos.

Fuentes de datos

Las **Fuentes de Datos** que alimentan el Datawarehouse son típicamente los sistemas transaccionales con los cuáles las empresas realizan la registración de sus transacciones.



Arquitectura del Datawarehouse - Procesos ETL

Los procesos ETL (por sus siglas en inglés, E=Extract, T=Transform, L=Load) consisten en procesos Batch (proceso en lote) que:

- **Extraen información** desde las distintas fuentes de datos.
- **Realizan transformaciones** simples o complejas (que incluyen normalmente algoritmos para mejorar la calidad de los datos) con el objetivo de
- **Cargan dichos datos** en el Datawarehouse.

Arquitectura del Datawarehouse - Procesos ETL

Estos procesos se ejecutan en forma automática y periódica (diariamente, semanalmente, mensualmente, cada hora, etc) y son esenciales para poder mantener la información del Datawarehouse actualizada, consistente con los sistemas fuentes, unificada, y de calidad.

Arquitectura del Datawarehouse - Bases de datos

El tercer componente es la **base de datos del Datawarehouse** que es un repositorio de datos modelado específicamente para realizar consultas a grandes volúmenes de datos. **Es básicamente una base de datos relacional** que puede tener un motor optimizado a tal fin, si el volumen de datos así lo requiere.

Arquitectura del Datawarehouse - Herramientas de visualización

El cuarto componente son las **herramientas de visualización**: son las herramientas con las que vamos a presentar la información. Pueden ser herramientas solo de visualización o herramientas que también permiten definir modelos de data mining o de data science más complejos.

Conclusión

En resumen, un Datawarehouse es un repositorio de datos:

- Construido y optimizado para **analizar y consultar grandes volúmenes de datos fácilmente**.
- Que nos permite **tener una visión unificada y con calidad de los datos** sin importar el origen del mismo.
- Debe brindarnos una **visión completa o de 360° de una empresa** dado que incluye todos los datos necesarios para su gestión.
- Es un componente necesario (pero no suficiente) para asegurar el gobierno de datos, que nos permita consolidar una **cultura orientada a datos** en la organización.

2

Data lake

DATA LAKE

El **Data Lake** va más allá del Data Warehouse superando algunas de sus limitaciones. Data Lake es la siguiente generación en materia de almacenamiento de datos.

Se trata de una forma distinta de orientar la utilización de los datos organizacionales y el reporting y la única manera de poder responder a consultas sobre el negocio, haciéndolo sin barreras.

DATA LAKE

La llegada del **Data Lake** no desplaza al Data Warehouse, sino que sirve para ampliar las capacidades de la organización en lo que concierne a su gestión de datos.

BENEFICIOS DE USAR DATA LAKE

Entre los beneficios de usar Data Lake para el trabajo con Big Data se encuentran:

- **Facilidad para innovar** en la utilización de los datos de la organización, tanto para reporting como para analytics.
- **Mayor agilidad**, por que se adapta a la necesidad del usuario respondiendo en el tiempo adecuado, incluso en tiempo real.
- **Más capacidad y flexibilidad** en un entorno en el que confluyen datos procedentes de la organización con información proveniente del exterior.

¿DATA LAKE O DATA WAREHOUSE?

DATA LAKE

Data Lake es mejor para gestionar grandes volúmenes de información no estructurada o semi estructurada.

DATA WAREHOUSE

Data Warehouse permite una visión unificada del negocio.

¿DATA LAKE O DATA WAREHOUSE?

Es posible utilizar ambos:

El **Data Lake** permitirá a los usuarios experimentar con diferentes **modelos de datos y transformaciones**, antes de configurar un nuevo esquema en un almacén de datos y servirá como área de ensayo, desde la cual suministrar datos al Data Warehouse. Y, a su vez, este almacén de datos limpios con valor conocido podrá **nutrir y retroalimentar al data lake corporativo**.

“


Obtener lo mejor de ambas soluciones es una cuestión de visión y arquitectura.

Y es la manera de no dejar escapar ningún dato valioso.




”

ARQUITECTURA DE DATAWAREHOUSE & DATALAKE



ARQUITECTURA DE DATA WAREHOUSE & DATA LAKE



CONCLUSIONES

El **Data Lake** es el concepto más moderno para centralizar datos para la toma de decisiones.

Los esquemas de ingesta de datos que se utilizan en los Data Lake, resultan muy eficientes para procesar grandes volúmenes de datos.

La posibilidad de almacenar **datos estructurados, semi estructurados y no estructurados** en una misma plataforma, con muy bajo costo es una gran **ventaja de los Data Lakes**.

Sin embargo el **Datawarehouse** sigue siendo **un componente clave para almacenar los datos estructurados** más relevantes para la toma de decisiones, por su facilidad para disponer un acceso a los datos rápido y seguro.

En una arquitectura moderna, encontraremos al Data Lake y al Datawarehouse integrados, y combinando sus ventajas.

¿Dudas?