

Exploración de datos

A dark blue, diagonal, triangular shape that starts from the bottom left corner and extends towards the top right, covering the lower half of the slide.

“

Antes de comenzar nuestro proceso de visualización resultará muy útil **explorar nuestros datos.**



”

Índice


1. ¿Qué es la exploración de datos?
2. Tipos de exploraciones
3. ¿Qué ventajas tiene la exploración de datos?
4. Conceptos estadísticos importantes

1

¿Qué es la exploración
de datos?

Exploración de datos

Es una investigación preliminar de los datos en búsqueda de tener un mejor entendimiento de las bases. Así podremos aplicar las transformaciones necesarias y luego sacar el mayor provecho posible a nuestro análisis.



Exploración de datos

Adicionalmente puede utilizarse para analizar los resultados de los análisis de datos.

También podés escucharlo como EDA (Exploratory Data Analysis/ **Análisis Exploratorio de Datos**).



2

Tipos de exploraciones

Sumarización

Es un resumen de los datos a través de medidas específicas que permiten captar **características de grandes volúmenes de datos**.


Por ejemplo, una tabla con la edad promedio de los habitantes por ciudad, veamos:

Ciudad	Edad promedio
Buenos Aires	35
Córdoba	42
Mendoza	38

Visualizaciones

Es la **forma de mostrar datos** de una forma gráfica o en tablas.

Resulta muy **útil** para la **interpretación** de **grandes volúmenes** de datos por cualquier receptor.



3

¿Qué ventajas tiene la exploración de datos?

Ventajas de la exploración de datos

Podrás utilizarla para los procesos de Data Manipulation y para analizar los resultados de un análisis.



Ventajas de la exploración de datos

Hace que la **interpretación** de los datos sea **accesible** para cualquier persona involucrada y nos ayudará a **alcanzar conclusiones rápidas y precisas**.



4

Conceptos estadísticos importantes

Frecuencia

Es la **cantidad de ocurrencias** dentro de la base. Es decir, **cuántas veces se repite** un determinado valor en la base.

Ciudad	Nacimientos
Buenos Aires	100
Córdoba	120
Santa Fe	100
Mendoza	100
Jujuy	200
Salta	300



Nacimientos	Frecuencia
100	3
120	1
200	1
300	1

Moda

Es el **valor que más se repite** en nuestra base, será aquel que tenga mayor frecuencia.

Ciudad	Nacimientos
Buenos Aires	100
Córdoba	120
Santa Fe	100
Mendoza	100
Jujuy	200
Salta	300



En este caso la moda será el valor de **100**, ya que se repite tres veces.

Promedio

Es un número representativo que busca ilustrar los valores de una base.

Ciudad	Nacimientos
Buenos Aires	100
Córdoba	120
Santa Fe	100
Mendoza	100
Jujuy	200
Salta	300



En este caso el promedio será el valor de **153** y surge de la suma de todos los valores dividido la cantidad de registros.

Percentil

Es el valor máximo de un determinado porcentaje de la base. Nos dirá hasta qué valor está comprendido un X % de la base de datos.

Ciudad	Nacimientos
Buenos Aires	100
Córdoba	120
Santa Fe	100
Mendoza	100
Jujuy	200
Salta	300



En este caso el percentil 85 será el valor de **225** ya que el 85 % de los datos (5 de 6) tienen un valor inferior a 225.

Mediana

Es el valor del medio de nuestra base, en otras palabras es el percentil 50.

Ciudad	Nacimientos
Buenos Aires	100
Córdoba	120
Santa Fe	100
Mendoza	100
Jujuy	200
Salta	300



En este caso la media será el valor de **110** ya que el 50 % de los datos (3 de 6) tienen un valor inferior a 110.

Muchas Gracias